

불량은 한 번에 잡는다

다이캐스팅 공정 실시간 불량 예측과 원인 분석 모델



김동욱



김동현



배진욱



유호빈



최민정

일오나!!



목차

Contents

01

문제정의

다이캐스팅
문제 해결 방안

02

데이터 분석

데이터 셋
EDA, 전처리
머신러닝

03

인사이트


대시보드
기대 효과



문제 정의



> DIE CASTING



정의

용융한 금속(아연, 구리, 알루미늄 등)을 금형에 고압으로 강제 주입시켜 제품을 만드는 공정

주 사용처

- 자동차 부품
- 전자제품 부품
- 기계 부품
- 항공우주 분야

> DEFECTS



Short Shot
미충전



Exfoliation
박리



Dent
함몰




Blow Hole
기공




Bubble
기포




Deformation
변형




Burnig Mark
소착



Stain
얼룩



Crack
균열



Impurity
불순물



Inclusions
개재물

> PROBLEM

Conventional Inspection Process



기존 검수 방식

- 작업자가 육안으로 외관 불량을 확인
- 사후 검사 중심 방식

문제점

- 판정 편차가 크고, 미세 불량 검출에 취약
- 불량 발생 후 대응하는 구조로 사후 검사 비용 증가 및 생산 효율 저하
- 동일 작업을 반복할수록 피로/판단 편차로 인해 일관된 성능 유지가 어려움

> SOLUTION

ML Inspection Process



자동 검수 ✓

- 공정·센서 데이터를 분석하여 실시간 불량 예측
- 불량 발생 선제적 대응

기대 효과 ✓

- 판정 편차 감소
- 공정 최적화 및 비용 절감

데이터 분석



> OVERVIEW

활용 데이터셋

주조 품질보증 AI 데이터셋
DieCasting_Quality_Raw_Data.csv
57개 컬럼 / 7535 행

전처리

Sensor 결측치 중앙값 대체
Defects 0과 1로 이진화
Defects 불량 유형 별 그룹화
멀티컬럼 → 단일 컬럼 변환
분석과 관계 없는 컬럼 제거
→ 10개 컬럼

EDA

독립 2표본 t-검정, Z-Score
히스토그램 통한 데이터 분포 파악
히트맵 상관관계 파악

Machine Learning Process

모델링 전략

SMOTE
Product_Type 통합
PR/ROC Curve 확인
Threshold 조정

머신러닝

데이터 바탕으로 머신러닝 모델 선정
Recall 70%, Precision 20% 목표로 진행

RANDOM FOREST LightGBM XGBoost

파이썬 라이브러리


python
NumPy Pandas
IP[y]: IPython
SciPy
statsmodels
scikit learn

> PIPELINE

Processing

Model

Insight



> DATASET

Process (공정 변수)

속도

Velocity_1-3, High_Velocity

시간

Spray_Time, Rapid_Rise_Time,
Pressure_Rise_Time, Cycle_Time

압력

Cylinder_Pressure,
Casting_Pressure

힘

Clamping_Force

기타(두께)

Biscuit_Thickness



독립 변수

Sensor (센서 변수)

온도

Factory_Temp, Coolant_Temp

습도

Factory_Humidity

압력

Coolant_Pressure,
Air_Pressure



독립 변수

Defects (결함 유형)

충전불량

Short_Shot

표면손상

Buring_Mark, Dent, Exfoliation,
Scratch, Stain

기포/내부

Blow_Hole, Bubble

구조결함

Crack, Deformation

이물


Contamination, Impurity,
Inclusions



종속 변수

> EDA

상관관계 히트맵



Process vs Defects


Sensor vs Defects

Process vs Process

Process, Sensor 독립변수가 종속변수인 Defects에 상관관계 계수가 **0.2이하**로 나타나고 있어,
 이는 하나의 종속변수에 여러가지의 독립변수가 연관되어있어 나타나는 현상으로 판단
 → 추후 SHAP, 머신러닝 통해 독립변수 간 종속변수 영향력을 봐야함

> EDA

데이터 분포, 이상치 확인 (Z-score)



Z-score 기준 이상치가 약 200개 정도 발견되었으나, 공정/센서 변수들의 이상치가 많지 않다고 판단 하에, 제거보다는 이상치 영향을 덜 받도록 모델 설계 필요

독립 2표본 t-검정 통한 불량 별 공정변수 통계적 확인

	defect	n_good	n_defect	sig_p_cnt	top5_vars(p<alpha)
0	Bubble	7456	77	22	Process_Cycle_Time, Process_Spray_Time, Process_Clamping_Force , Process_Casting_Pressure, Process_Cylinder_Pressure
1	Stain	7346	169	22	Process_Casting_Pressure, Process_Cycle_Time, Process_Spray_2_Time, Process_Spray_1_Time, Process_Spray_Time
2	Exfoliation	7240	290	21	Process_Cylinder_Pressure, Process_High_Velocity, Process_Spray_2_Time, Process_Clamping_Force , Process_Casting_Pressure
3	Blow_Hole	7172	335	20	Process_Cylinder_Pressure, Process_High_Velocity, Process_Cycle_Time, Process_Clamping_Force , Process_Spray_1_Time
4	Deformation	7366	167	20	Process_id, Process_High_Velocity, Process_Cylinder_Pressure, Process_Spray_2_Time, Process_Casting_Pressure
5	Short_Shot	6865	653	18	Sensor_Melting_Furnace_Temp, Process_Casting_Pressure, Process_Clamping_Force , Process_Spray_1_Time, Process_Spray_Time
6	Contamination	7524	11	17	Process_Spray_1_Time, Process_Spray_2_Time, Process_Casting_Pressure, Process_Cycle_Time, Process_Cylinder_Pressure
7	Impurity	7528	7	16	Process_Spray_2_Time, Process_Casting_Pressure, Process_Cylinder_Pressure, Process_High_Velocity, Process_Clamping_Force
8	Buring_Mark	7530	5	15	Process_Cylinder_Pressure, Process_Casting_Pressure, Process_Spray_2_Time, Process_id, Process_High_Velocity
9	Dent	7524	11	6	Sensor_Factory_Humidity, Sensor_Factory_Temp, Process_Pressure_Rise_Time, Process_Spray_2_Time, Process_High_Velocity

머신러닝 단계에서는 이 t-검정 결과를 불량 별로 정상·불량 간 분포 차이가 검증된 변수(top5/유의 변수)를 “우선 피쳐 후보·해석 포인트”로 삼아 모델 학습 및 SHAP 중요도와 교차 검증함으로써, 성능 개선과 원인 변수 설명력을 동시에 강화하는 근거로 활용

> ENGINEERING


Defects 그룹화

충전불량	Short Shot
기포/내부	Bubble, Blow Hole
표면손상	Dent, Scratch, Stain, Burning mark, Exfoliation
기타	Crack, Deformation, Impurity, Contamination, Inclusion

Defects 그룹화

비슷한 현상끼리 그룹화 및
구조 결함, 이물 부분이 상대
적으로 적어 기타로 그룹화

불량유형	불량 개수
충전 불량	670
표면손상	500
기포/내부	442
구조결함	172
이물	19




불량유형	불량 개수
충전 불량	670
표면손상	500
기포/내부	442
기타	191

Type 병합

Defect 그룹이 product type별로 불균형이 심해, 하나로 결합하여 진행

Product Type	충전불량	기포/내부	표면손상	기타
1	229	78	300	169
2	441	364	200	22



충전불량	기포/내부	표면손상	기타
670	442	500	191

> ENGINEERING

SMOTE


불량 데이터 비율이 낮은 그룹 1:1 비율로 SMOTE

기타	개수
0	5875
1	191
SMOTE 적용후	
기타	개수
0	5875
1	5875




측정값이 아닌 컬럼 삭제

Process | id
Process | Shot
Process | High_Velocity
Sensor | Melting_Furnace_Temp
Sensor | Factory_Humidity
Process | Clamping_Force
Process | Velocity_3
Sensor | Coolant_Pressure
Process | Cycle_Time
Sensor | Factory_Temp
Process | Velocity_1
Sensor | Air_Pressure
Process | Casting_Pressure
Sensor | Coolant_Temp
Process | Velocity_2
Process | Pressure_Rise_Time
Process | Biscuit_Thickness
Process | Spray_Time
Process | Rapid_Rise_Time
Process | Cylinder_Pressure
Process | Spray_2_Time
Process | Spray_1_Time
Process | Product_Type
Sensor | Coolant_Temp_Min
Sensor | Coolant_Temp_Max
Sensor | Air_Pressure_Max
Sensor | Air_Pressure_Min
Sensor | Factory_Temp_Min
Sensor | Factory_Temp_Max
Sensor | Factory_Humidity_Min
Sensor | Factory_Humidity_Max



Process | High_Velocity
Sensor | Melting_Furnace_Temp
Sensor | Factory_Humidity
Process | Clamping_Force
Sensor | Coolant_Pressure
Process | Velocity_3
Sensor | Coolant_Temp
Sensor | Air_Pressure
Sensor | Factory_Temp
Process | Cycle_Time
Process | Velocity_1
Process | Casting_Pressure
Process | Velocity_2
Process | Spray_Time
Process | Pressure_Rise_Time
Process | Biscuit_Thickness
Process | Rapid_Rise_Time
Process | Cylinder_Pressure
Process | Spray_2_Time
Process | Spray_1_Time
Process | Product_Type

> MODEL SELECTION





성능 지표 탐색

ROC 모델이 전반적으로 양품과 불량을 혼동하지 않고
명확하게 구분하고 있음을 증명

해당 그래프를 통해 본다고 하면,
RF와 LGBM이 좋아 보이나,
추가적으로 PC Curve, PC-AUC 값도 확인이 필요함

> MODEL SELECTION





PR-AUC
높게 나오는
Light GBM

성능 지표 기반 모델 선정

PR 데이터 불균형 상황에서도 High Precision & High Recall을 유지
실제 불량 탐지 성능이 매우 우수함을 시각적으로 확인


그렇기에 전체적인 불량유형에 대해 안정적으로 잡아낼 수 있는
LGBM을 선택

또한 Threshold를 변곡점으로 보이는 구간인 0.6~0.8사이에서
최적값을 찾아 진행



> EVALUATION

	RandomForest				XGBoost				LightGBM			
	accuracy	precision	recall	f1	accuracy	precision	recall	f1	accuracy	precision	recall	f1
defect_group												
기타	0.973457	0.416667	0.131579	0.200000	0.974784	0.500000	0.184211	0.269231	0.974121	0.466667	0.184211	0.264151
기포/내부	0.960186	0.818182	0.409091	0.545455	0.961513	0.647059	0.750000	0.694737	0.979429	0.925373	0.704545	0.800000
충전불량	0.946914	0.950000	0.425373	0.587629	0.942269	0.688000	0.641791	0.664093	0.968812	0.988764	0.656716	0.789238
표면손상	0.959522	0.897959	0.440000	0.590604	0.957532	0.640625	0.820000	0.719298	0.974784	0.918919	0.680000	0.781609



분류 성능 지표

- Accuracy** 전체 샘플중 TP 와 TN 비율
- Precision** 모델이 Positive라고 판단한 것 중, 실제로 Positive인 샘플
- Recall** 실제 Positive샘 중 모델이 Positive로 판정한 비율
- F1-Score** Precision과 Recall의 조화평균

Light GBM이 F-1 Score : 79로 가장 뛰어난 성능을 보임

> EVALUATION

threshold = 0.68

Random Forest

충전불량	Actually (정상)	Actually (불량)
Predicted (정상)	1944 (TN)	65 (FN)
Predicted (불량)	116 (FP)	136 (TP)
기포/내부	Actually (정상)	Actually (불량)
Predicted (정상)	1411 (TN)	56 (FN)
Predicted (불량)	8 (FP)	32 (TP)
표면손상	Actually (정상)	Actually (불량)
Predicted (정상)	1401 (TN)	58 (FN)
Predicted (불량)	6 (FP)	42 (TP)
기타	Actually (정상)	Actually (불량)
Predicted (정상)	1463 (TN)	33 (FN)
Predicted (불량)	6 (FP)	5 (TP)

XGBoost



충전불량	Actually (정상)	Actually (불량)
Predicted (정상)	1334 (TN)	48 (FN)
Predicted (불량)	39 (FP)	86 (TP)
기포/내부	Actually (정상)	Actually (불량)
Predicted (정상)	1383 (TN)	22 (FN)
Predicted (불량)	36 (FP)	66 (TP)
표면손상	Actually (정상)	Actually (불량)
Predicted (정상)	1361 (TN)	18 (FN)
Predicted (불량)	46 (FP)	82 (TP)
기타	Actually (정상)	Actually (불량)
Predicted (정상)	1445 (TN)	27 (FN)
Predicted (불량)	24 (FP)	11 (TP)

LGBM

충전불량	Actually (정상)	Actually (불량)
Predicted (정상)	1372 (TN)	46 (FN)
Predicted (불량)	1 (FP)	88 (TP)
기포/내부	Actually (정상)	Actually (불량)
Predicted (정상)	1414 (TN)	26 (FN)
Predicted (불량)	5 (FP)	62 (TP)
표면손상	Actually (정상)	Actually (불량)
Predicted (정상)	1401 (TN)	32 (FN)
Predicted (불량)	6 (FP)	68 (TP)
기타	Actually (정상)	Actually (불량)
Predicted (정상)	1461 (TN)	31 (FN)
Predicted (불량)	8 (FP)	7 (TP)

불량-정상: 불량이라고 예측했지만 실제로 정상 (FP)
 정상-불량: 정상이라고 예측하고, 실제로 불량 (FN)

> MODEL VALIDATION



SHAP 주요 변수 해석 (LGBM, 충전불량)

- 목표: 머신러닝 모델의 예측 결과를 '어떤 변수(Feature)가 얼마나 기여했는지' 직관적으로 설명
- 장점: 개별 예측에 대한 투명한 근거 제시 및 전반적인 모델 이해도 향상
- 글로벌 상위 변수: High_Velocity, Clamping_Force, Melting_Furnace_Temp, Spray_2_Time, Casting_Pressure/Factory_Humidity 중심으로 확인됨
- Waterfall로 특정 샷에서 각 변수가 불량 확률을 +/- 방향으로 얼마나 밀었는지 기여도를 분해해 설명 가능
- SHAP(test) 상위 변수는 “일반화 구간에서 예측 기여 큰 변수”라 설명력/설득력이 큼
- 내장 feature importance는 “학습 분기 기반”이라 순위가 일부 달라도 정상이며, 둘 다 상위면 핵심 변수 신뢰도 높음

model	defect_group	rank_1_feature	rank_2_feature	rank_3_feature	rank_4_feature	rank_5_feature
LGBM 머신러닝 feature importance	기타	Process High_Velocity	Sensor Melting_Furnace_Temp	Sensor Factory_Humidity	Sensor Coolant_Pressure	Process Velocity_1
	기포/내부	Process High_Velocity	Sensor Melting_Furnace_Temp	Sensor Factory_Humidity	Process Velocity_3	Process Velocity_1
	충전불량	Process High_Velocity	Sensor Melting_Furnace_Temp	Sensor Factory_Humidity	Process Velocity_3	Process Velocity_1
	표면손상	Process High_Velocity	Sensor Melting_Furnace_Temp	Sensor Factory_Humidity	Process Velocity_3	Sensor Coolant_Pressure


> DECISION LOGIC



인사이트



> DASHBOARD



STEP 1. 지금 공정은 정상인가?

불량률 / 양품률 / 사이클 타임(-> 불량유형 분포)으로
한눈에 생산 상태 이상 여부 판단

STEP 2. 문제가 있다면, 어디서 발생했는가?

불량 유형 분포, 최근 100샷 트렌드 그래프
고빈도 불량 유형과 발생 패턴 식별

STEP 3. 왜 발생했고, 무엇을 조정해야 하는가?

원인 변수와 조정 방향을 수치로 제시

> MACHINE LEARNING

머신러닝 모델 도출

- 1.한정된 공정 데이터 센서 기반 불량 예측 모델 구성
- 2.전처리 → SMOTE → PR-AUC 통한 최적 모델 선정 → 실제 모델 학습 → SHAP 통한 설명 가능성까지 하여 신뢰성 확보
- 3.LGBM을 최종 후보로 선택한 정량 근거 (기타 제외)
 - a. 충전불량: Recall 0.66 / Precision 0.99, FP 1, FN 46
 - b. 기포/내부: Recall 0.70 / Precision 0.93, FP 5, FN 46
 - c. 표면 손상: Recall 0.68 / Precision 0.92, FP 6, FN 32

<결론>


XGBoost 대비 Recall이 일부 낮더라도,
FP(추가검사/재검사)를 억제할 수 있는 높은 Precision구조가
확인되어 LGBM이 운영 비용라인 가동 측면에서 유리한 형태
(조건:FP,FN에 대한 가격이 산정되어있을 경우)

SHAP기반 인사이트

- 1.모든 불량에서 주요 영향 변수들이 반복적으로 상위에 나타남
 - a.Velocity 계열
 - b.Clamping, Casting pressure
 - c.센서 (Melting Furnace Temp, Factory Humidity, Coolant 등)
- 2.이러한 주요 변수들이 불량에 어느정도 영향을 끼치는지도 확인
이 가능하여 독립변수 간 상대적 중요도 확인이 가능함
- 3.결과적으로 예측(Detect) + 원인 추정(Explain) + 운영지표
(FP/FN) 관리를 동시에 충족하는 방향으로 LGBM 적용 타당성
확보



> BUSINESS IMPACT



지출 비용 변화 추이

FN 손실 비용 (개당)

₩ **3,000**

FP 손실 비용 (개당)


₩ **20,000**

머신러닝 활용 절감 비용 (10일)

₩ **3,503,430**

머신러닝 기반 비용 절감 효과 계산

수집한 데이터를 기반으로 FN/FP 손실 비용을 정의하고, 이를 적용해 3개월 단위로 머신러닝 기반 품질 관리 공장과 기존 육안 검사만 수행하는 공장의 총 지출 비용 변화를 비교 및 시각화




Speed



검사 속도 상승

Growth rate



기대 성장률

작업 시간 단축

50%

검사 속도 향상

100배

영업 이익 상승

15%

➤ FUTURE WORK

프로젝트 회고

- 비용 손실/효과(ROI) 정량화에 한계 존재함: 육안검사 Baseline(비교군) 데이터 부족함
- 기타 그룹은 재현 데이터가 적어 자동 판정만으로 운영하기 어려워 육안검사 병행 필요함
- 독립변수 간 상관관계/다중공선성 점검이 충분하지 않았음(VIF/Correlation 기반 제거·정제 미흡함)
- 앙상블 시도했으나 LGBM 단독 대비 성능 개선 폭이 제한적이었음

개선 방향

- 향후 Baseline(육안검사 기간) 데이터 확보를 최우선으로 설정함 → ROI 산정 가능해짐
- 상관관계 분석 강화함(VIF, Correlation Heatmap 등) → 모델 안정성/해석력 향상 기대됨
- 앙상블 확장보다 하이퍼파라미터 튜닝·Feature Engineering에 집중하는 전략이 더 효율적임
- 추가 데이터 축적 → 모델 고도화 → FP/FN 비용 정의 포함한 비용 효과 정량 체계 구축 필요

> REFERENCE

머신러닝 관련 웹사이트

[ML] 분류 성능 지표: Precision(정밀도), Recall(재현율), F1-score

https://en.wikipedia.org/wiki/Confusion_matrix

https://en.wikipedia.org/wiki/Receiver_operating_characteristic

https://cosmiccoding.com.au/tutorials/pr_vs_roc_curves/

<https://zephyrus1111.tistory.com/279>

<https://www.kitech.re.kr/webzine/view.php?idx=451&m=04>

머신러닝 관련 Paper, Report

Uyan, T.Ç., Otto, K., Silva, M.S. et al. Industry 4.0 Foundry Data Management and Supervised Machine Learning in Low-Pressure Die Casting Quality Improvement. Inter Metalcast 17, 414–429 (2023). <https://doi.org/10.1007/s40962-022-00783-z>

Ministry of SMEs and Startups, and KAIST(Korea Advanced Institute of Science and Technology). (2022, December 23). Casting quality assurance AI dataset. Korea AI Manufacturing Platform(KAMP). <https://www.kamp-ai.kr/>

Pechmann, A.; Kanli, S. Towards Sustainable Manufacturing: Deployable Deep Learning for Automated Defect Detection in Aluminum Die-Cast X-Ray Inspection at Hengst SE. Appl. Sci. 2025, 15, 13134. <https://doi.org/10.3390/app152413134>

Okuniewska, A., Perzyk, M., & Kozłowski, J. (2023). Machine Learning Methods for diagnosing the causes of die-casting defects. Computer Methods in Materials Science, 23(2), 45–56. <https://doi.org/10.7494/cmms.2023.2.0809>



THANK YOU FOR LISTENING

김동욱



김동현



배진욱



유희빈



최민정

